

PRÉSENTATION

PROJET ANR SCREAM

William PENSEC



Maître de Conférences
LIRMM – Université de Montpellier
Montpellier

23 septembre 2025



Cursus

- **2024 : Doctorat en Informatique**
Lab-STICC - Univ. Bretagne Sud - Lorient
- **2024 : Postdoctorat**
Laboratoire Hubert Curien - Univ. Jean Monnet - Saint-Étienne
- **2025 : Maître de Conférences - Section 61**
LIRMM et Polytech Montpellier - Univ. Montpellier - Montpellier



Domaines de recherche

- Sécurité matérielle sur RISC-V,
- Attaques physiques (Injection de fautes),
- Sécurité des réseaux de neurones.

Thèse de Doctorat

Contexte

- Systèmes embarqués sont de plus en plus utilisés dans des domaines sensibles.
- Ils deviennent cibles des menaces logicielles (exploitation de vulnérabilités) et physiques (injection de fautes, observation).
- Mécanismes de sécurité logicielle insuffisants.

Problématique

Comment maintenir une protection maximale contre les attaques logicielles en présence d'attaques physiques ?

Problématique

Comment maintenir une protection maximale contre les attaques logicielles en présence d'attaques physiques ?

Méthode

- Sécurisation du mécanisme DIFT, utilisé pour contrer les attaques logicielles.
- Objectif de le rendre robuste face aux attaques par injection de fautes.
- Proposition de contremesures légères et adaptées.

- ▶ Nous avons montré que le DIFT est vulnérable contre des attaques par injections de fautes en prenant en compte des modèles de fautes plus ou moins complexes.
- ▶ Proposition de 3 contremesures avec 5 stratégies d'implémentations :



- ▶ Nous avons montré que le DIFT est vulnérable contre des attaques par injections de fautes en prenant en compte des modèles de fautes plus ou moins complexes.
- ▶ Proposition de 3 contremesures avec 5 stratégies d'implémentations :
 - ▶ codes correcteurs d'erreurs,
 - ▶ surcoût d'aire inférieure à 8%,
 - ▶ aucun impact sur les performances,
 - ▶ bonne efficacité en termes de sécurité (99.99% de taux de détection/correction avec des modèles de fautes complexes).



Perspectives

- Évaluation de contremesures plus robustes pouvant corriger plus d'erreurs (BCH).
- Comparaison de ces contremesures par rapport à celles proposées.

Publications

- Création d'un outil pour l'évaluation de la sécurité, disponible en open-source – FISSA.
- 3 articles de conférences (dont un best paper award).


Post-doctorat

Contexte


- IA utilisé dans plein de domaines dont l'IoT (*edge computing*)
- Entraînement coûteux d'un réseau de neurones (GPT-4 $\approx 100M\$$ / Gemini 1 $\approx 191M\$$).

Objectif


- Cloner un réseau de neurones déjà entraîné (MNIST, Iris, ...) en utilisant des injections de fautes dans la mémoire flash.




- Modèle original. On a accès aux entrées et aux valeurs de sorties.



- On injecte une faute sur le MSB du poids afin de fauter le signe. Le signe est forcé en négatif.
 - S'il y a un changement de sortie, alors le poids était positif.




- On injecte une faute sur le MSB du poids pour fauter le signe. Le signe est forcé en négatif :
 - S'il n'y a aucun changement, alors le poids était négatif.




- On obtient une cartographie complète des signes des poids.

Complete mapping of weight signs




- On construit un système d'équations comprenant les "*chemins actifs*".

Construction of simple active paths equations



- On construit un système d'équations comprenant les "*chemins actifs*".

Construction of complex active paths equations





$$\begin{aligned}
 & [[w_{11}^1 \times w_{11}^2 \times w_{11}^3 \times w_1^4 = -0.6], [w_{11}^1 \times w_{11}^2 \times w_{12}^3 \times w_2^4 = -0.1], [w_{11}^1 \times w_{12}^2 \times w_{22}^3 \times w_2^4 = -0.9], \\
 & \quad [w_{12}^1 \times w_{21}^2 \times w_{11}^3 \times w_1^4 = -0.1], [w_{12}^1 \times w_{21}^2 \times w_{12}^3 \times w_2^4 = -0.03] \\
 & [w_{21}^1 \times w_{11}^2 \times w_{11}^3 \times w_1^4 = -0.1], [w_{21}^1 \times w_{11}^2 \times w_{12}^3 \times w_2^4 = -0.02], [w_{21}^1 \times w_{12}^2 \times w_{22}^3 \times w_2^4 = -0.2], \\
 & \quad [w_{22}^1 \times w_{21}^2 \times w_{11}^3 \times w_1^4 = -0.3], [w_{22}^1 \times w_{21}^2 \times w_{12}^3 \times w_2^4 = -0.05]]
 \end{aligned}$$

- Résolution du système grâce à un solveur python qui donnera une solution pour chacun des poids positifs et poids négatifs contenus dans les équations.

- Calcul de chacune des valeurs des poids négatifs restants grâce à un deuxième solveur.

- Évaluation du modèle obtenu pour vérifier s'il est équivalent à l'original.
 - ▶ **Modèle aléatoire** : S'il est équivalent alors $MSE == 0$ ou proche.
 - ▶ **Modèle entraîné** : S'il est équivalent alors précision (*accuracy*) du modèle identique à celle du modèle original.

- Clonages réussis sur de petits modèles aléatoires et sur des modèles entraînés avec le dataset Iris (MSE à 0 ou précision du modèle obtenue égale à l'original).
- Plus le réseau est profond et plus c'est compliqué.
- Peu importe le nombre de neurones sur une couche.
- Objectif de poursuivre avec des expérimentations réelles en utilisant un laser multispots.



Situation actuelle

ANR SCREAM

- Sécurité matérielle
- RISC-V
- Implémentation et évaluation de contremesures
- Intégration dans l'ANR SCREAM - co-encadrement d'Ali avec Pascal et Florent

PRÉSENTATION

PROJET ANR SCREAM

William PENSEC

Maître de Conférences
LIRMM – Université de Montpellier
Montpellier

Merci pour votre attention.

